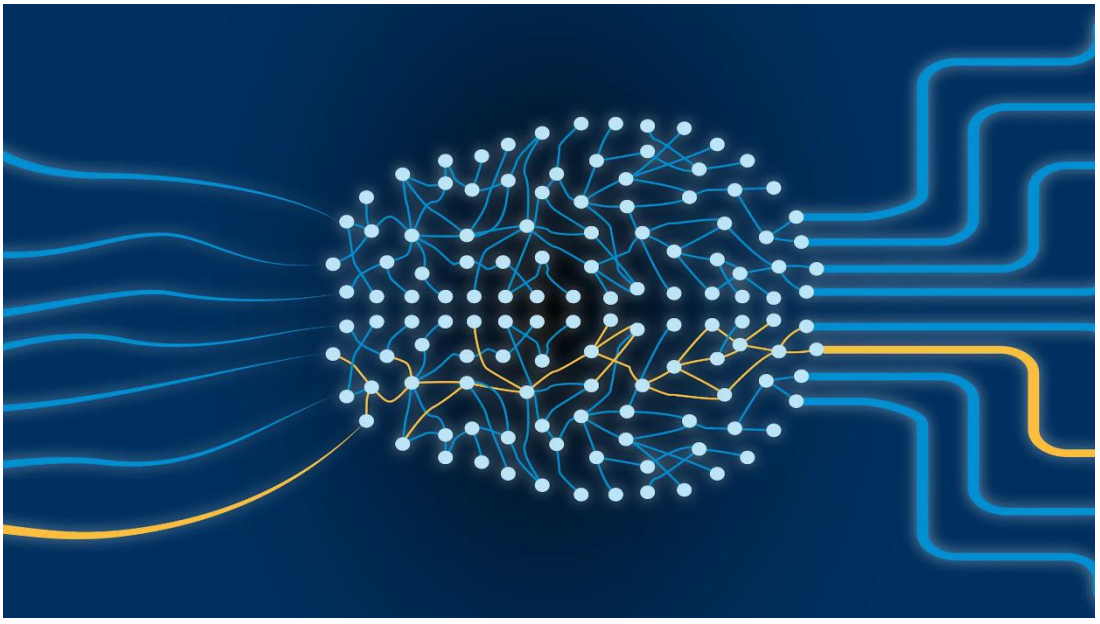
DAKAR INSTITUTE OF TECHNOLOGY

PROJET DE DEEP LEARNING



Détection des maladies des cultures par

CNN

Participant : Oumaro Titans DJIGUIMDE

Ousseynou DIOUF

Encadrant : Mr Amadou Alwaly NDIAYE

Annee : 2026

Rapport technique : détection des maladies de la tomate par CNN

Un CNN conçu from scratch atteint 98,3 % de rappel macro sur des images de laboratoire, mais seulement 18,4 % sur des photos de terrain. La meilleure stratégie testée, l'entraînement mixte, remonte à 31,4 % : c'est encore insuffisant pour un outil d'agriculteur.

1. Contexte et problème

Une coopérative agricole veut permettre à ses maraîchers de photographier une feuille de tomate et d'obtenir un diagnostic préliminaire. Nous concevons et évaluons un classifieur CNN pour **7 maladies foliaires de la tomate et la classe saine**.

La difficulté n'est pas d'obtenir un score élevé sur des images de laboratoire : les modèles dépassent facilement 98 % sur PlantVillage. Elle est de **conserver des performances utiles sur des photos de terrain**, prises avec un fond chargé et une lumière variable.

Question de recherche : de combien chute un CNN entraîné en laboratoire quand on le teste sur le terrain, et quelles stratégies réduisent cet écart sans modèle pré-entraîné ?

Résultat principal : le rappel macro passe de **98,3 %** sur PlantVillage à **18,4 %** sur PlantDoc, à peine au-dessus du hasard (12,5 % pour 8 classes). L'entraînement mixte PlantVillage + PlantDoc ramène l'écart à 31,4 %, la meilleure valeur obtenue.

2. Données et préparation

Nous gardons uniquement les **8 classes tomate communes** à PlantVillage (laboratoire) et PlantDoc (terrain), soit 15 820 images après nettoyage. *Target Spot* (absente de PlantDoc) et *Spider mites* (2 images dans PlantDoc) sont exclues.

Classe	pv_train	pv_val	pv_test	pd_train	pd_val	pd_test
bacterial_spot	1 074	214	212	66	16	27
early_blight	716	142	142	53	13	22
late_blight	1 065	217	218	66	17	28
leaf_mold	682	135	135	54	14	23
septoria_leaf_spot	1 072	215	213	89	23	37
yellow_leaf_curl_virus	1 070	213	217	45	11	19
mosaic_virus	266	53	54	33	8	13
Classe	pv_train	pv_val	pv_test	pd_train	pd_val	pd_test

healthy	1 066	220	214	38	9	16
Total	**7 011**	**1 409**	**1 405**	**444**	**111**	**185**

Effectifs de l'exécution sur Colab, avec au plus 1 500 images PlantVillage par classe (graine 42) : 9 825 images PlantVillage et 740 PlantDoc.

Observations :

PlantVillage est environ 13 fois plus grand que PlantDoc. La mosaïque est la classe rare des deux côtés (373 images PlantVillage au total, 13 images dans pd_test). Toutes les images PlantVillage font 256 × 256 px ; celles de PlantDoc vont de 130 à 4 320 px de large (médiane environ 600 × 540).

PlantDoc montre souvent plusieurs feuilles, des mains, de la terre et parfois des filigranes (« alamy stock photo ») : ce sont des images du web, dont certaines étiquettes peuvent être approximatives.

Avec 13 à 37 images de test par classe, une seule image change le rappel d'une classe de 3 à 8 points.

Découpage sans fuite :

PlantVillage : 70 / 15 / 15 %, stratifié et **groupé par feuille**. Plusieurs photos d'une même feuille partagent un suffixe de nom de fichier (ex. *Leaf 259.1*, *Leaf 259.2*) et restent dans le même split. Un contrôle automatique vérifie qu'aucun groupe n'est partagé.

PlantDoc : 4 doublons exacts supprimés (hash MD5). Le test officiel ne compte qu'environ 70 images tomate ; nous refaisons un tirage stratifié de 25 % pour le test, puis 20 % du reste pour la validation. pd_test n'est jamais utilisé pour l'entraînement ni pour le choix d'un modèle.

-

3. Modèles et protocole expérimental

Modèles (Keras, entrées 128 × 128 × 3) :

Modèle	Architecture	Rôle
MLP	images réduites à 64 × 64 et aplaties, Dense 512 → 256, dropout 0,5	baseline sans structure spatiale
CNN A	3 blocs (2 × Conv 3×3 + MaxPool), 32-64-128 filtres, sans batch norm, GAP, dropout	variante de référence
CNN B	comme A, avec batch normalization	effet de la batch norm
Modèle	Architecture	Rôle
CNN C	comme B, 4 blocs (jusqu'à 256 filtres)	effet de la profondeur

Nombre de paramètres : MLP 6 425 352 ; CNN A 288 040 ; CNN B 289 384 ; CNN C 1 177 192.

Entraînement : Adam (lr 10^{-3}), entropie croisée, poids de classes équilibrés, early stopping sur la perte de validation (patience 6) et réduction du learning rate sur plateau.

Expériences de robustesse (avec la meilleure variante CNN) :

Exp.	Entraînement	Validation	Idée testée
E0	PlantVillage	pv_val	mesure de la chute labo → terrain
E1	PlantVillage + augmentation (rotation, retournement, recadrage, luminosité, contraste)	pv_val	variations photométriques et géométriques
E2	E1 + changement de fond (fonds tirés de pd_train)	pv_val	casser le raccourci « fond uniforme »
E3	E2 puis fine-tuning sur pd_train (lr 10^{-4})	pd_val	adaptation avec peu de données terrain
E4	PlantVillage + PlantDoc échantillonnés 50/50	pd_val	entraînement mixte
E5	pd_train seul	pd_val	référence : PlantVillage aide-t-il ?

Métriques : précision, rappel et F1 par classe ; **rappel macro (métrique principale)**, car une maladie non détectée coûte plus cher qu'une fausse alerte ; F1 macro ; rappel « malade » (feuilles malades non classées saines) ; taux de fausse alerte (feuilles saines classées malades). L'accuracy est rapportée à titre indicatif seulement.

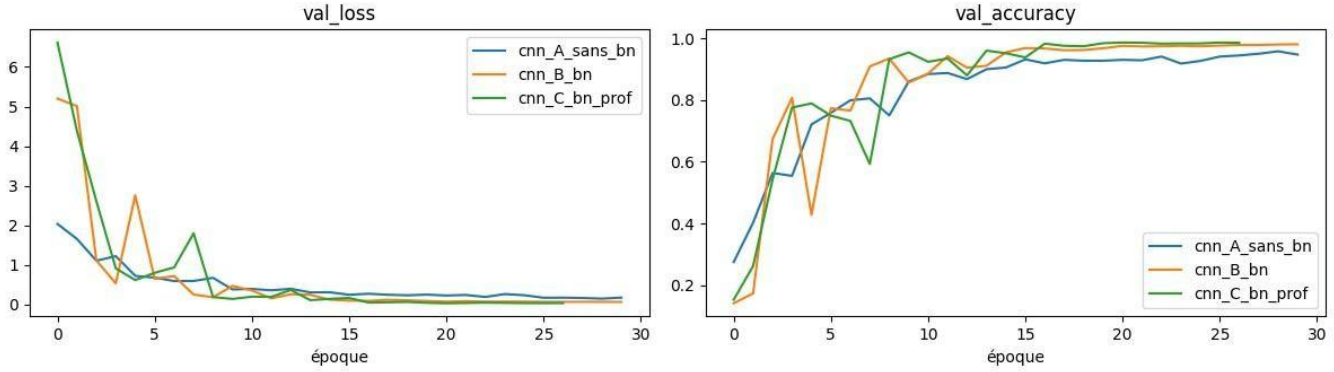
Changement de fond : un masque de feuille approximatif (saturation HSV > 0,25, lissé) sépare la feuille du fond gris de PlantVillage ; le fond est remplacé, avec une probabilité de 0,6, par une image de pd_train. Les étiquettes PlantDoc ne sont pas utilisées.

4. Résultats

Les CNN dépassent 96 % en laboratoire, mais aucun modèle ne dépasse 31,4 % de rappel macro sur le terrain.

4.1 MLP contre CNN (laboratoire)

Modèle	Paramètres	Rappel macro pv_test	F1 macro pv_test	Rappel macro pd_test
MLP	6 425 352	13,5 %	5,2 %	11,6 %
CNN A (sans BN)	288 040	96,0 %	95,5 %	—
CNN B (BN), retenu	289 384	98,3 %	98,1 %	18,4 % (= E0)
CNN C (BN, profond)	1 177 192	98,7 %	98,7 %	—

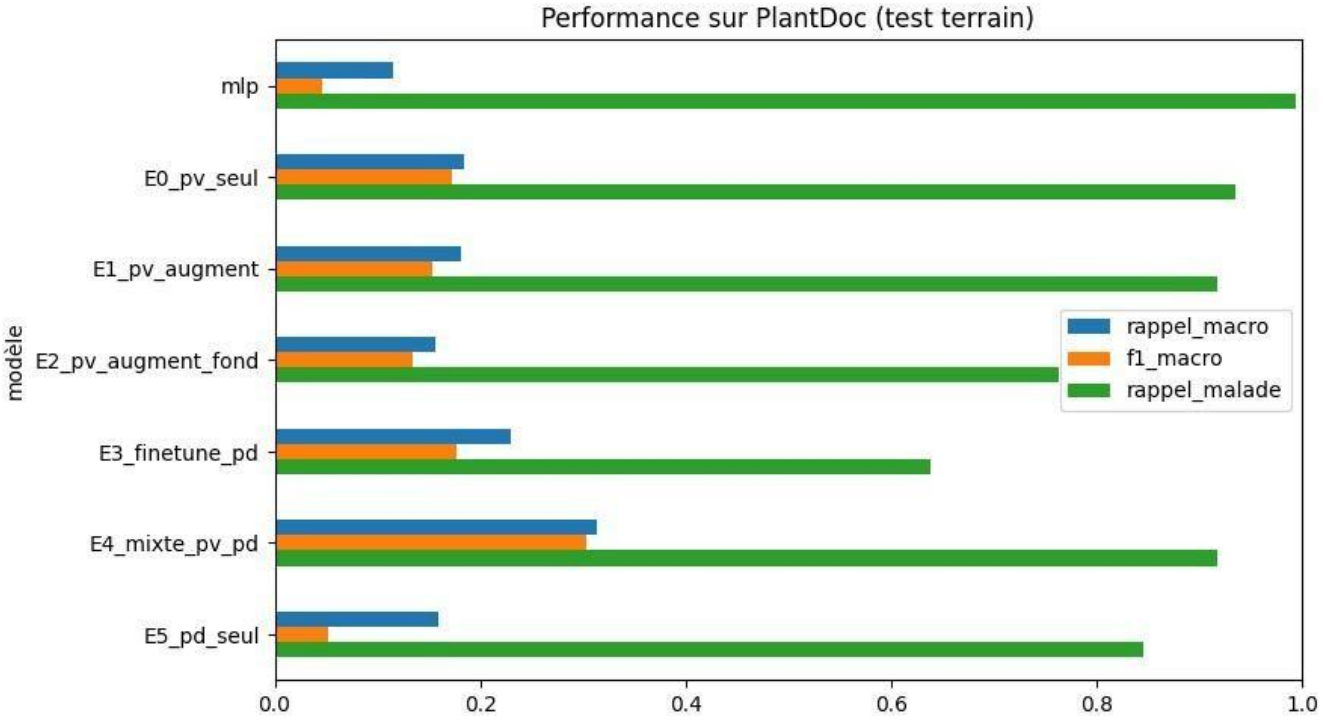


Le **MLP n'apprend pas** : sa perte reste bloquée à 2,05, proche de ln(8) = 2,08, le niveau du hasard, et il prédit presque toujours « septoriose ». En aplatissant l'image, il perd la structure spatiale, avec 22 fois plus de paramètres qu'un CNN. La **batch normalization** apporte +2,3 points, après des débuts plus instables (pics de perte de validation). Le **4e bloc** n'apporte que +0,4 point pour 4 fois plus de paramètres : nous retenons la variante B, plus légère pour un smartphone. Aucun surapprentissage visible.

4.2 Laboratoire contre terrain

Exp.	Rappel macro pv_test	Rappel macro pd_test	Chute (points)	F1 macro pd_test	Rappel « malade » pd_test	Fausse alerte pd_test
E0 PlantVillage seul	98,3 %	18,4 %	79,9	17,3 %	93,5 %	93,8 %

E1 + augmentation	85,8 %	18,2 %	67,6	15,4 %	91,7 %	93,8 %
E2 + changement de fond	73,8 %	15,7 %	58,1	13,4 %	76,3 %	75,0 %
E3 fine-tuning PlantDoc	66,2 %	23,0 %	43,2	17,7 %	63,9 %	18,8 %
Exp.	Rappel macro pv_test	Rappel macro pd_test	Chute (points)	F1 macro pd_test	Rappel « malade » pd_test	Fausse alerte pd_test
E4 mixte	65,6 %	**31,4 %**	34,2	**30,3 %**	91,7 %	75,0 %
E5 PlantDoc seul	12,3 %	16,0 %	—	5,2 %	84,6 %	56,2 %



- **Le fossé est massif (E0)** : 98,3 % → 18,4 %. Le rappel « malade » de 93,5 % est trompeur : le modèle déclare presque tout malade, y compris 94 % des feuilles saines. • **L'augmentation classique ne suffit pas (E1)** : aucun gain sur le terrain, et 12,5 points perdus en laboratoire.
- **Le changement de fond a échoué (E2)** à cause de notre implémentation : les fonds collés, tirés de PlantDoc, contiennent déjà des feuilles malades d'autres classes. Le modèle sous-apprend (72 % d'accuracy d'entraînement). Ce résultat ne réfute pas l'idée.
- **Le fine-tuning (E3)** gagne 4,6 points, mais déclare saines 36 % des feuilles malades, l'erreur la plus coûteuse. La perte de validation remonte dès la 2e époque : 444 images ne suffisent pas.

L'entraînement mixte (E4) est la meilleure stratégie : 31,4 %, soit 2,5 fois le hasard et +13 points par rapport à E0. Il reconnaît le mieux le virus des feuilles jaunes (58 %) et le mildiou (54 %), très mal la cladosporiose et l'alternariose (9 %).

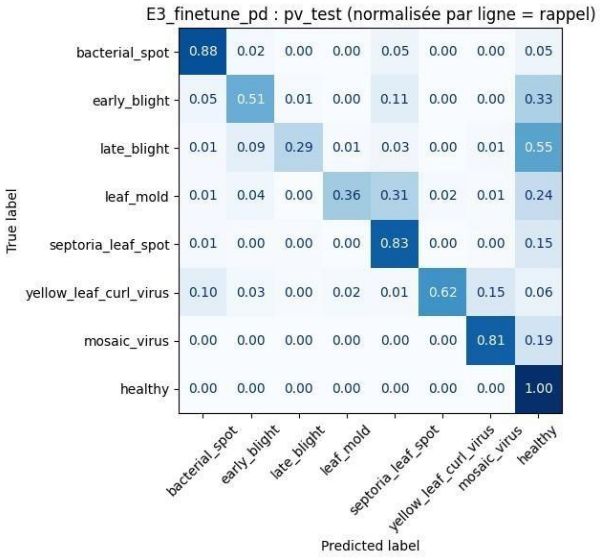
PlantVillage reste utile (E5) : entraîné sur PlantDoc seul, le CNN s'effondre (16,0 %). ⚠ Avec 185 images de test et une seule graine, les écarts entre E0, E1, E2 et E5 (16 à 18 %) ne sont pas significatifs. L'avance de E4 (+13 points) est plus nette, mais devrait être confirmée avec plusieurs graines.

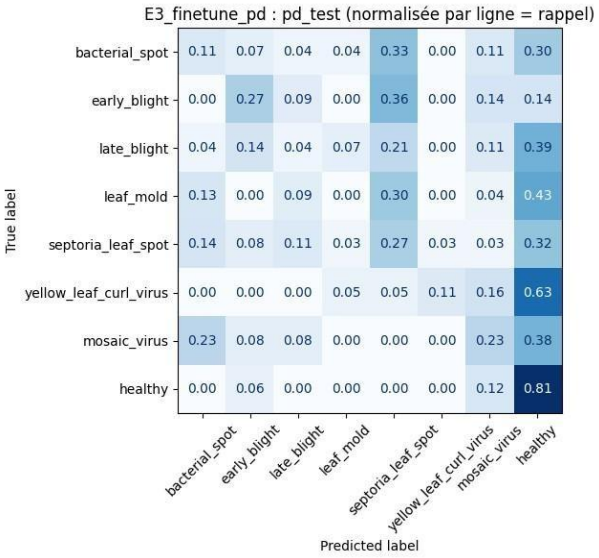
5. Analyse des erreurs et explicabilité

Le modèle fine-tuné (E3) déclare « saines » une grande partie des feuilles malades photographiées sur le terrain : pour l'agriculteur, cela signifie ne pas traiter.

L'analyse porte sur E3, fixé dans le code avant les résultats. Le meilleur modèle terrain est E4 ; son analyse détaillée est une amélioration possible.

5.1 Matrices de confusion et rappel par classe





Ce que montrent les matrices :

Sur le terrain, la colonne « sain » absorbe 30 à 63 % de chaque maladie (63 % pour le virus des feuilles jaunes). Seule la classe saine est bien reconnue (81 %).

En laboratoire, le modèle a oublié : 55 % des mildious et 33 % des alternarioses sont classés sains, alors que le modèle de départ les reconnaissait presque tous.

Les confusions entre maladies vont surtout vers la septoriose (21 à 36 %), une maladie à petites taches, visuellement proche de l'alternariose et de la tache bactérienne.

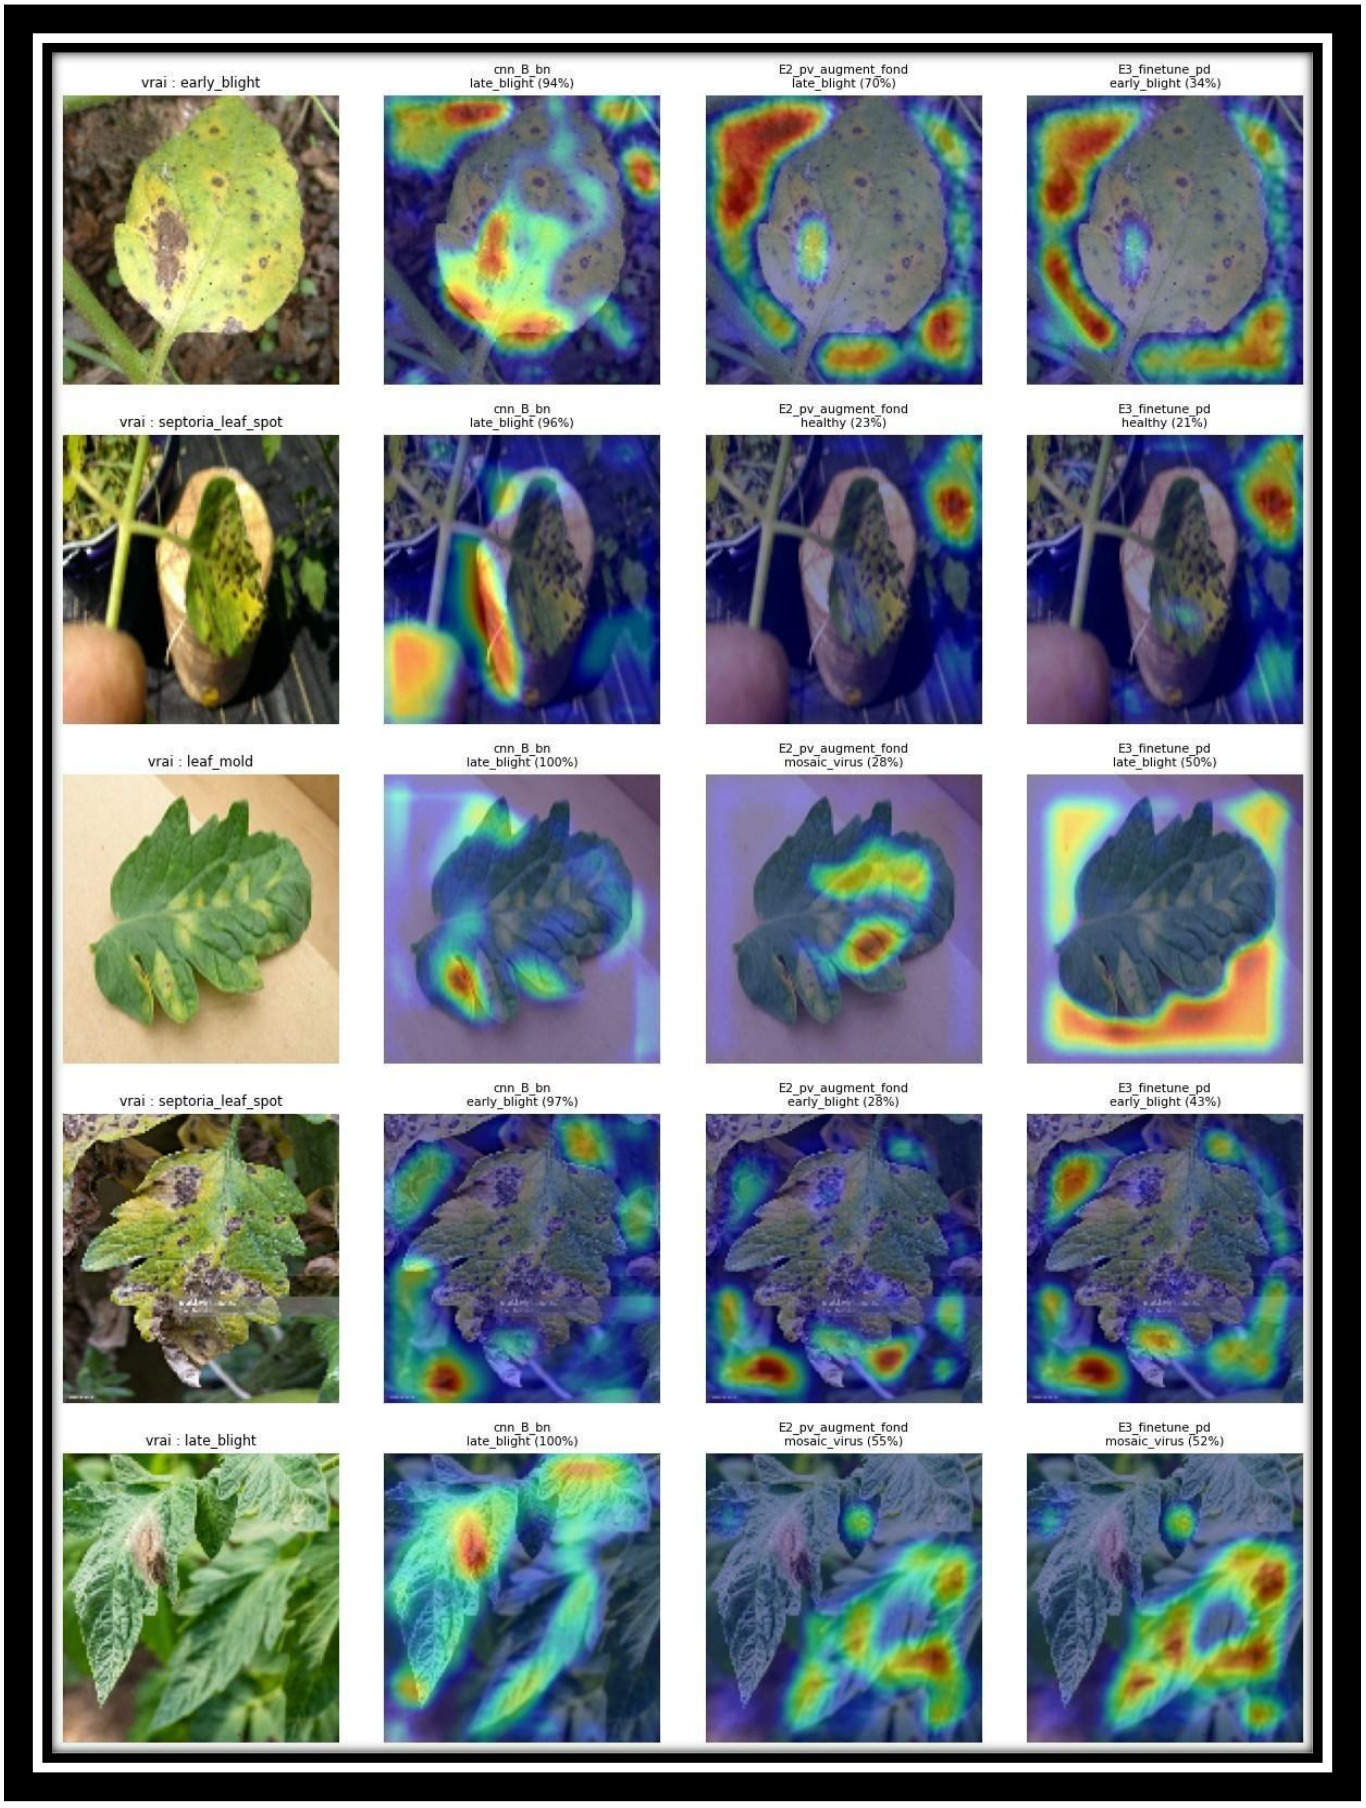
5.2 Exemples mal classés

Image	Vraie classe	Prédite (confiance)	Hypothèse sur la cause
#129	virus des feuilles jaunes	sain (100 %)	plant entier, dizaines de feuilles : symptômes invisibles à 128 × 128 px
Image	Vraie classe	Prédite (confiance)	Hypothèse sur la cause
#63	mildiou	sain (100 %)	lésion petite à la base, fond textile sombre jamais vu
#58	mildiou	sain (99 %)	grosse lésion visible, mais fond bleu vif très inhabituel
#118	septoriose	sain (98 %)	filigrane « alamy stock photo » posé sur les taches
#85	cladosporiose	sain (98 %)	main dans l'image, symptômes discrets
#90	cladosporiose	sain (96 %)	image floue, plusieurs feuilles
#127	virus des feuilles jaunes	septoriose (85 %)	jaunissement général, symptômes proches

11 des 12 erreurs les plus confiantes sont des maladies classées « saines ». Le fine-tuning sur 444 images semble avoir appris un raccourci : une photo de terrain, verte et chargée, est « saine ». Les causes récurrentes sont plusieurs feuilles par image, des lésions trop petites après redimensionnement,des fonds inédits et des filigranes : une partie relève des données (images du web) .


#129 vrai : yellow_leaf_curl_virus
prédit : healthy (100%)
#63 vrai : late_blight
prédit : healthy (100%)
#58 vrai : late_blight
prédit : healthy (99%)
#118 vrai : septoria_leaf_spot
prédit : healthy (98%)
#85 vrai : leaf_mold
prédit : healthy (98%)
#90 vrai : leaf_mold
prédit : healthy (96%)
#110 vrai : septoria_leaf_spot
prédit : healthy (95%)
#59 vrai : late_blight
prédit : healthy (91%)
#8 vrai : bacterial_spot
prédit : healthy (89%)
#133 vrai : yellow_leaf_curl_virus
prédit : healthy (87%)
#127 vrai : yellow_leaf_curl_virus
prédit : septoria_leaf_spot (85%)
#120 vrai : septoria_leaf_spot
prédit : healthy (83%)

5.3 Grad-CAM


vrai : early_blight
cnn_B_bn
late_blight (94%)
E2_pv_augment_fond
late_blight (70%)
E3_finetune_pd
early_blight (34%)
vrai : septoria_leaf_spot
cnn_B_bn
late_blight (96%)
E2_pv_augment_fond
healthy (23%)
E3_finetune_pd
healthy (21%)
vrai : leaf_mold
cnn_B_bn
late_blight (100%)
E2_pv_augment_fond
mosaic_virus (28%)
E3_finetune_pd
late_blight (50%)
vrai : septoria_leaf_spot
cnn_B_bn
early_blight (97%)
E2_pv_augment_fond
early_blight (28%)
E3_finetune_pd
early_blight (43%)
vrai : late_blight
cnn_B_bn
late_blight (100%)
E2_pv_augment_fond
mosaic_virus (55%)
E3_finetune_pd
mosaic_virus (52%)

Modèle	Part de l'attention sur la feuille (pv_test)	Surface de la feuille dans l'image
E0 PlantVillage seul	59 %	43 %
E2 + changement de fond	69 %	43 %
E3 fine-tuning	68 %	43 %

En laboratoire, tous les modèles regardent la feuille plus que sa surface ne le justifie, et le changement de fond fait gagner 10 points d'attention sur la feuille. Mais on trouve des raccourcis : sur une petite feuille de mildiou, E0 répond juste à 90 % en regardant surtout les coins du fond gris.

Sur le terrain, l'attention se disperse : E0 regarde des tiges, une main ou les bords de l'image ; E2 et E3 se concentrent souvent sur le fond. Le seul cas où la lésion est nettement regardée (mildiou) est aussi le seul où E0 répond juste avec confiance. La concentration gagnée en laboratoire ne se transfère pas au terrain, ce qui est cohérent avec la chute des performances.

6. Limites, risques et pistes d'amélioration

Le prototype n'est pas prêt pour un déploiement : il n'a jamais été testé sur des photos prises dans les champs de la coopérative.

Limites des données

PlantDoc provient d'images trouvées sur internet, pas de champs ouest-africains : variétés, sols et lumière diffèrent.

- Test terrain petit (185 images, 13 à 37 par classe) : métriques par classe peu fiables. Seules 7
- maladies sont couvertes. Le flétrissement bactérien, la fusariose, les ravageurs ou les carences

seront classés à tort dans l'une des 8 classes.

Possibles erreurs d'étiquetage dans PlantDoc (annotations faites à partir d'images du web).

Limites des méthodes

- Masque de feuille par seuil de saturation : il échoue sur les feuilles pâles ou jaunies.
- **Erreur de conception de E2** : les fonds viennent de photos PlantDoc qui contiennent déjà des feuilles malades. Cela ajoute des symptômes d'autres classes (bruit d'étiquette) et explique en partie l'échec de E2. Il faudrait des fonds sans tomate.

Une seule graine par expérience ; les écarts de moins de 5 points ne sont pas interprétables.

Seuls des CNN from scratch ont été testés, comme le demandait l'énoncé ; le transfer learning est la piste la plus prometteuse.

Risques pour l'agriculteur

- Faux « sain » : la maladie s'étend sans traitement.
- Mauvais diagnostic : produit inadapté, dépense inutile, exposition aux pesticides. Excès de
- confiance dans l'outil au détriment du conseiller agricole.

Mesures et pistes

- Afficher la confiance et répondre « incertain, consultez un conseiller » sous un seuil. Ajouter une
- classe « autre / hors sujet » (images qui ne sont pas des feuilles de tomate).
- Collecter et étiqueter des photos locales avec des agronomes, puis réentraîner.
- Transfer learning (MobileNetV2, EfficientNet) pour un modèle léger et plus robuste. Évaluer sur
- plusieurs graines et en validation croisée sur PlantDoc.

Références

Hughes, D. P. et Salathé, M. (2015). *An open access repository of images on plant health to enable the development of mobile disease diagnostics*. arXiv:1511.08060. Données : PlantVillage-Dataset.

Singh, D., Jain, N., Jain, P., Kayal, P., Kumawat, S. et Batra, N. (2020). *PlantDoc: A Dataset for Visual Plant Disease Detection*. CoDS-COMAD 2020, p. 249-253. Données : PlantDoc-Dataset.

Selvaraju, R. R. et al. (2017). *Grad-CAM: Visual Explanations from Deep Networks via Gradientbased Localization*. ICCV 2017.

Ioffe, S. et Szegedy, C. (2015). *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. ICML 2015.

Les deux jeux de données sont sous licence Creative Commons Attribution 4.0.